

Identificación de especies de aves, anfibios, mamíferos e insectos a partir de grabaciones de audio en el Valle del Magdalena Medio

Duvan Fernando Lombana Bejarano

Universidad Nacional de Colombia
Redes Neuronales, Arquitecturas y Aplicaciones

11 de junio de 2026

Índice

1. Introducción	2
2. Trabajo Relacionado	2
3. Dataset y Características	3
4. Métodos	3
4.1. Arquitectura del Modelo	3
4.2. Regularización	4
4.3. Estrategia de Validación y Función de Pérdida	4
4.4. Métrica de Evaluación	4
4.5. Optimizadores	5
4.6. Planificadores de la tasa de aprendizaje	5
5. Resultados	5
5.1. Análisis de las Curvas ROC	6
5.1.1. AdamW + CosineAnnelingLR	6
5.1.2. AdamW + ReduceLROnPlateau	7
5.1.3. SGD + CosineAnnelingLR	9
6. Conclusiones	10
7. Repositorio de GitHub	11
8. Bibliografía	11

1. Introducción

Cuando se realizan esfuerzos de restauración ecológica con el objetivo de devolverle a los hábitats su biodiversidad y funcionalidad natural, se usan métodos para evaluar los resultados de estas medidas como determinar las variaciones y dinámicas poblacionales de las especies que allí conviven¹.

Medir el comportamiento de la flora es un proceso estático y predecible, pero rastrear la fauna exige un esfuerzo mayor como los censos de biodiversidad tradicionales en los que un grupo de investigadores deben realizar caminatas a lo largo del día intentando estimar la abundancia de animales a través de la agudeza de sus sentidos, esto en algunos casos conlleva datos perdidos o mal registrados debido al sesgo y error humano, sin contar que las especies más tímidas o en peligro de extinción pueden huir de la presencia humana, llevando a pensar que la especie ya no habita el entorno.

Con el fin de mejorar este seguimiento, que en algunos casos es costoso y logísticamente complejo, se introdujo el Monitoreo Acústico Pasivo (MAP), que consiste en instalar grabadoras digitales en el ecosistema para registrar continuamente o en intervalos de tiempo, los sonidos del ambiente sin alterar el comportamiento de la fauna; sin embargo esto produce un "tsunami de datos acústicos", con lo que el reto ahora es poder procesar estas miles de horas de audio.

Pensando en este problema se lanzó *BirdCLEF+ 2025*, una competencia global de Inteligencia Artificial organizada en la plataforma *Kaggle* por instituciones como el Instituto Humboldt de Colombia, Google Research, iNaturalist y la Universidad Tecnológica de Chemnitz, cuyo objetivo principal es invitar a expertos en datos a desarrollar algoritmos capaces de identificar múltiples grupos taxonómicos de forma automática a partir de archivos de audio capturados en la *Reserva Natural El Silencio*, ubicada en el Valle del Magdalena Medio², que fue destruida en el pasado por la ganadería extensiva y ahora atraviesa un proceso de restauración ecológica.

En este proyecto se replica uno de los modelos presentados para esta competencia, con un enfoque en evaluar empíricamente el comportamiento del modelo frente a diferentes configuraciones de optimizadores y planificadores de tasa de aprendizaje (*learning rate schedulers*), optimizando la métrica oficial de validación.

2. Trabajo Relacionado

El presente estudio toma como referencia directa y réplica metodológica la solución de línea base desarrollada en 2025 por *Kadircan İdrisoğlu*, Científico de datos e Ingeniero de Machine Learning originario de Estambul, Turquía de la Universidad Eskişehir Osmangazi. İdrisoğlu trabaja como Científico de datos en World from Space, una compañía europea enfocada en el análisis de datos geoespaciales y de observación de la Tierra mediante satélites³. Dicha propuesta destaca por el uso eficiente de una arquitectura convolucional optimizada, el empleo de técnicas de aumento de datos espaciales como *Mixup* o *SpecAugment*, y un esquema sólido de validación cruzada diseñado para mitigar el desbalance masivo de clases inherente a las grabaciones de campo.

El trabajo original se encuentra en el siguiente enlace:

<https://www.kaggle.com/code/kadircandrisolu/efficientnet-b0-pytorch-train-birdclef-25>

Las aproximaciones modernas en la clasificación bioacústica han mostrado que las redes neuronales convolucionales (CNN) usadas en modelos consolidados de análisis de imágenes como *Inception* y *ResNet* entrenadas mediante aprendizaje por transferencia (*Transfer Learning*), son una herramienta bastante precisa para procesar archivos como los espectrogramas Mel⁴.

La contribución principal de este informe radica en una extensión experimental y un

análisis comparativo de la fase de entrenamiento. Específicamente, se evalúa el comportamiento del modelo frente a combinaciones de optimizadores adaptativos y tradicionales como *AdamW* y *SGD* y planificadores de tasa de aprendizaje como *CosineAnnealingLR* y *ReduceLROnPlateau*, monitorizando su impacto en la métrica oficial *Macro ROC-AUC*.

3. Dataset y Características

El conjunto de datos empleado consiste en 28 564 grabaciones cortas de sonidos individuales de aves, anfibios, mamíferos e insectos de 32 kHz en formato *.ogg* extraídos de la base oficial de *BirdCLEF*, que a su vez han sido subidos por usuarios de *xeno-canto.org*, *iNaturalist* y el Archivo Sonoro Colombiano (CSA) del Instituto Humboldt de Investigación de Recursos Biológicos en Colombia⁵. Las grabaciones han sido realizadas en la Reserva Natural El Silencio, Colombia y buscan identificar cerca de 206 especies.



Figura 1: Reserva Natural El Silencio.

También se tiene un archivo de metadatos etiquetados asociados a los audios que proporcionan información sobre la especie principal que se presenta en la grabación, otras especies que se escuchan de fondo, las coordenadas del lugar de grabación, el nivel de calidad del audio, el nombre del autor del audio y su colección de origen.

El conjunto de datos se define formalmente como un problema multietiqueta, debido a que cada segmento de audio puede registrar simultáneamente una especie principal y múltiples especies de fondo.

4. Métodos

La arquitectura de entrenamiento se implementó utilizando la librería PyTorch un modelo preentrenado de la librería *timm*.

4.1. Arquitectura del Modelo

Se tomó como base el modelo EfficientNet-B0 que clasifica imágenes en 1 000 categorías y es preentrenado con ImageNet, siendo hasta 8,4 veces más pequeño y 16 veces más rápido que modelos como ResNet, cuenta con una resolución de entrada de 224×224 píxeles y 5,3 millones de parámetros.




Figura 2: Arquitectura EfficientNet-B0.

Con el objetivo de aplicar el aprendizaje por transferencia, se realizó una adaptación para que recibiera como entrada los espectrogramas en blanco y negro, ya que el modelo está diseñado para recibir imágenes a color de 3 canales RGB, luego se elimina la capa de clasificación original y se reemplaza por una capa que solo deja pasar los datos, posteriormente se agrega una capa de Agrupamiento Promedio Global que aplanar los datos, es decir, cambia el tamaño de cada tensor a (*tamaño del lote*, 1, 1, 1) al realizar el promedio de los valores de la matriz que representa cada espectrograma. Después se añade una nueva capa lineal adaptada al número de especies que se deben clasificar.

4.2. Regularización

Durante el entrenamiento se emplean cuatro técnicas de aumento de datos, en la parte inicial de cada época para cada espectrograma hay una probabilidad de 0,5 de que a este se le aplique alguna de las siguientes procedimientos:

- Enmascaramiento temporal (se borran fragmentos de tiempo agregando franjas negras verticales en el espectrograma).
- Enmascaramiento de frecuencia (se borran bandas de frecuencia agregando franjas negras horizontales en el espectrograma).
- Brillo y contraste aleatorio (se multiplica cada píxel del espectrograma por una ganancia (número) aleatoria y se le suma un valor de sesgo fijo a toda la muestra por igual).

Posteriormente, también se usa el *Mixup*, que consiste en combinar linealmente pares de espectrogramas x_i, x_j aleatorios dentro de cada lote con un coeficiente λ extraído de una distribución Beta siguiendo la siguiente proporción:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j$$

Las etiquetas también se fusionan siguiendo esta idea, esto provoca que la predicción del modelo sea ahora una proporción.

4.3. Estrategia de Validación y Función de Pérdida

Se utilizó un esquema de Validación Cruzada de 5 Particiones, es decir, se dividen los datos en 5 pedazos en los que cada uno mantiene la misma proporción de especies que el dataset completo. El modelo se entrena 5 veces desde cero, usando 4 pedazos en entrenamiento y el restante para validación, en cada intento se intercambian los pedazos para asegurar que el modelo es verdaderamente bueno y no que obtuvo un buen rendimiento por un corte de validación fácil. Debido a la naturaleza multietiqueta del espacio de salida, la función de costo seleccionada fue la Entropía Cruzada Binaria con Logits Integrados *BCEWithLogitsLoss*, definida para N clases como:

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_{i=1}^N (y_i \cdot \ln(\sigma(x_i)) + (1 - y_i) \cdot \ln(1 - \sigma(x_i)))$$

donde $\sigma(x)$ representa la función sigmoide.

4.4. Métrica de Evaluación

La evaluación se rige bajo la métrica *Macro ROC-AUC*, que calcula el área bajo la curva de características operativas del receptor de forma independiente para cada una de

las especies y promedia aritméticamente sus resultados, asegurando una protección de rendimiento equitativa tanto para especies comunes como para especies raras en peligro de extinción, esto es útil dado que *BirdCLEF* tiene un problema severo de clases desbalanceadas (hay especies de aves con miles de grabaciones y otras con apenas dos o tres), esto obliga al modelo a ser igual de bueno identificando especies comunes y raras, ya que todas pesan lo mismo en el puntaje final.

4.5. Optimizadores

El optimizador ajusta los pesos de la red a partir de su predicción. El modelo permite evaluar las siguientes opciones:

- Adam: Algoritmo muy eficiente para encontrar el mínimo de una función de costo y acelerar el entrenamiento, sin embargo tiene una falla al aplicar la regularización, el problema surge porque la penalización L2 que usa el optimizador se mezcla matemáticamente con el cálculo de la tasa de aprendizaje adaptativa de Adam, lo que reduce su efectividad para pesos grandes y evita la generalización en datos nuevos.
- AdamW: Este algoritmo soluciona el problema de Adam, desvinculando el decaimiento del peso de los pasos de cálculo de gradientes, proporcionando un enfoque más eficaz para modelos grandes y mejorando la generalización., la *W* en su nombre se refiere a *Weight Decay* (Decaimiento de Peso)⁶.
- Descenso de Gradiente Estocástico (SGD): Este algoritmo aplica la misma tasa de aprendizaje Estricta a todos los pesos por igual

4.6. Planificadores de la tasa de aprendizaje

El planificador se utiliza para reducir el tamaño de la tasa de aprendizaje con el pasar de las épocas. El modelo permite evaluar las siguientes opciones:

- ReduceLROnPlateau: Planificador que ajusta dinámicamente la tasa de aprendizaje durante el entrenamiento, más precisamente, reduce la tasa cuando el rendimiento del modelo se estanca (entra en una meseta).
- StepLR: Planificador que reduce la tasa de aprendizaje cada cierto número de épocas en un factor fijo gamma, lo que permite que el modelo aprenda rápido al inicio y realice ajustes finos conforme se estabiliza.
- CosineAnnealingLR: Planificador que reduce la tasa de aprendizaje siguiendo la curva de coseno (disminuye lentamente al principio, luego cae de forma rápida y al final se estabiliza con un descenso suave cerca de cero). Este método permite afinar el entrenamiento con mayor precisión al realizar el descenso continuo en lugar de reducir la tasa abruptamente.

5. Resultados

Se ejecutaron tres pruebas experimentales usando la GPU T4 de Google Colab, variando la combinación del optimizador y planificador sobre la primera partición *Fold 0* durante un ciclo de diez épocas, esto debido a la limitación de los recursos computacionales. Para asegurar que los resultados no se afectaran por la partición de los datos se fijó una semilla para mantener siempre la misma separación en los conjuntos, obteniendo de este modo 22 851 datos para entrenamiento y 5 713 para validación, los resultados comparativos se sintetizan en la Tabla 1.

Configuración Experimental	Train Loss	Train AUC	Val Loss	Val AUC
AdamW + CosineAnnealingLR	0.0075	0.9943	0.0156	0.9443
AdamW + ReduceLROnPlateau	0.0068	0.9953	0.0164	0.9429
SGD + CosineAnnealingLR	0.1469	0.5085	0.1427	0.5218

Tabla 1: Resultados cuantitativos comparativos de los experimentos de entrenamiento.

5.1. Análisis de las Curvas ROC

A través de las funciones de visualización introducidas en el ciclo de validación, se capturó la evolución temporal del aprendizaje. A continuación se presentan con mayor detalle los experimentos realizados.

5.1.1. AdamW + CosineAnnealingLR

Este experimento tuvo un tiempo de ejecución de 5 horas 23 minutos y 18 segundos







Figura 3: Curvas ROC durante el experimento 1.



(a) Curva AUC-ROC.



(b) Pérdida en entrenamiento y validación.



(c) Evolución de la tasa de aprendizaje.

Figura 4: Curvas de rendimiento del modelo durante el experimento 1.

Como se observa en el comportamiento analizado, este modelo muestra una tasa de falsos positivos decreciente, empujando la curva macro de discriminación hacia el extremo superior izquierdo de forma constante con el paso de las épocas.

5.1.2. AdamW + ReduceLROnPlateau

Este experimento tuvo un tiempo de ejecución de 5 horas 7 minutos y 15 segundos




Figura 5: Curvas ROC durante el experimento 2.




Figura 6: Curvas de rendimiento del modelo durante el experimento 2.

Este comportamiento demuestra que el extractor de características logra separar efi-

cientemente los patrones visuales de los espectrogramas y además permite afirmar que el optimizador hace el "trabajo pesado", dado que los dos experimentos mostrados dieron resultados casi idénticos, concluyéndose así que en este ecosistema de datos, el optimizador adaptativo *AdamW* es el responsable del éxito, sin importar tanto si el planificador bajaba el ritmo por tiempo o por estancamiento.

5.1.3. SGD + CosineAnnelingLR

Este experimento tuvo un tiempo de ejecución de 5 horas 10 minutos y 8 segundos




Figura 7: Curvas ROC durante el experimento 3.




Figura 8: Curvas de rendimiento del modelo durante el experimento 3.

Como *SGD* no tiene tasas de aprendizaje adaptativas por cada parámetro, encontró dificultades, pues la naturaleza multietiqueta de los datos donde la inmensa mayoría de las clases en un audio dado son negativas (es decir, se escucha 1 especie, y las otras especies son 0), hacen que para reducir la pérdida matemática lo más rápido posible, el modelo pudo predecir que no hay ningún pájaro en absoluto, así como el 99 % de las etiquetas reales en la matriz son ceros, predecir "solo ceros" hace que la pérdida matemática baje drásticamente (porque acierta casi todo). Sin embargo, la métrica Macro AUC castiga severamente esto, porque evalúa la capacidad de detectar los Verdaderos Positivos.

6. Conclusiones

La investigación determinó el impacto directo que poseen los hiperparámetros de optimización sobre datos bioacústicos, mostrando la superioridad del optimizador adaptativo *AdamW*, el cual alcanzó un rendimiento sobresaliente con un Macro ROC-AUC de más de 0,94 en ambos escenarios de planificación (*CosineAnnealing* y *ReduceLROnPlateau*) tras solo 10 épocas.

La similitud en los resultados de los experimentos 1 y 2 sugieren que, dada la capacidad de *AdamW* para calcular tasas de aprendizaje individuales por parámetro, la red logra una convergencia rápida y estable hacia mínimos globales, haciendo que la elección del planificador sea un factor secundario para este número de épocas. La pérdida de validación decreciente hacia niveles cercanos a cero confirma una alta capacidad de discriminación sin evidencia de sobreajuste temprano.

Por otro lado, el experimento 3 evidenció una limitación crítica del optimizador *SGD* en este dominio. A pesar de registrar un descenso consistente en la función de pérdida, el modelo fue incapaz de superar un Macro ROC-AUC de 0,53. Este fenómeno puede atribuirse a la naturaleza multietiqueta y a la alta escasez (*sparsity*) de positivos en la matriz de etiquetas, el optimizador *SGD* tendió a colapsar sus predicciones hacia la clase mayo-

ritaria. Esto minimiza artificialmente el error global de entropía cruzada, pero destruye la capacidad del modelo para distinguir *Verdaderos Positivos*, lo cual es penalizado por la métrica Macro ROC-AUC que pondera a todas las especies por igual.

Se concluye que, para la clasificación masiva de espectrogramas con arquitecturas convolucionales, el uso de optimizadores con tasas adaptativas y decaimiento de pesos desacoplado como *AdamW* mejoran la velocidad de convergencia y evitan el colapso del modelo frente al desbalance de clases intrínseco de la ecología acústica.

7. Repositorio de GitHub

El código fuente completo utilizado en los experimentos y las rutinas de visualización del espectrograma se encuentran disponibles de manera pública para reproducibilidad en el siguiente enlace:

<https://github.com/tu-usuario/birdclef-audio-classification>

8. Bibliografía

1. Facultad de Estudios Ambientales y Rurales. Restauración ecológica: ¿cómo se recuperan los ecosistemas dañados? [Internet]. Bogotá: Bitácora EAR, Pontificia Universidad Javeriana; 2026 [citado 10 de jun. de 2026]. Disponible en: <https://fear.javeriana.edu.co/w/blog/que-es-restauracion-ecologica>
2. Fundación Natura Colombia. Reserva Biológica El Silencio [Internet]. Bogotá: Fundación Natura; 2024 [citado 10 de jun. de 2026]. Disponible en: <https://natura.org.co/reservas/reserva-biologica-silencio/>
3. İdrisoğlu, K. (s.f.). Perfil de LinkedIn. LinkedIn. Disponible en: <https://www.linkedin.com/in/kadircan-idrisoglu-569467231/>
4. Dias, F. F., Ponti, M. A., & Minghim, R. (2025). Enhancing sound-based classification of birds and anurans with spectrogram representations and acoustic indices in neural network architectures. *Ecological Informatics*, 90, 103232. <https://sciencedirect.unalproxy.elogim.com/science/article/pii/S1574954125002419>
5. Kaggle. BirdCLEF+ 2025 [Internet]. San Francisco: Kaggle; 2025 [citado 10 de jun. de 2026]. Disponible en: <https://www.kaggle.com/competitions/birdclef-2025/overview>
6. Pykes, K. (2024, 22 de octubre). Tutorial del Optimizador AdamW en PyTorch. DataCamp. <https://www.datacamp.com/es/tutorial/adamw-optimizer-in-pytorch>